“中国电子杯”第三界高校 ICT 产教融合创新大赛

初赛作品报告

作品题目：智采关系引擎

赛题编号：F5-002

摘要

本报告围绕“智采关系引擎”项目的实体抽取技术路线与数据质量治理展开研究。针对招采公告多格式附件、跨页表格、扫描污染及字段归属复杂等问题，设计了融合**布局感知解析、按需 OCR、Qwen 与 DeepSeek 动态协同抽取、原文证据追踪及金额一致性校验**的技术方案，通过规则与模型分工处理，提高非结构化招采数据的可解析性与结果可追溯性。

研究基于 1038 篇采购公告、13018 次末端文件及 4481 条结构化标的，分析文件重复、七字段缺失和典型抽取错误，并结合 Gold50 历史基准及 69 条扫描明细开展质量验证。扫描专项修复后，品牌、规格型号和单价的正确项分别增加 4 条、3 条和 3 条；来源修正后的内部专项诊断中，七字段整体 F1 达到 89.08%，单价、数量和总价三个关键字段的专项 F1 达到 96.87%。相关指标均保留独立评价口径，不等同于原始模型的盲测成绩。

研究形成了从**复杂附件解析、智能实体抽取到原文证据校验与异常治理**的完整处理思路，为招采信息结构化、关系建模及后续业务分析提供了数据基础。

关键词： 招采实体抽取；多模型协同；布局感知解析；原文证据追踪；数据质量治理

目 录

1 技术路线对比报告 1

1.1 研究目标与技术方案 1

1.1.1 赛题要求与实体抽取目标 1

1.1.2 数据特点与主要技术难点 2

1.1.3 技术路线设计与评价方法 4

1.2 实体抽取技术路线对比 5

1.2.1 规则与快速表格抽取方案 5

1.2.2 大模型直接抽取方案 6

1.2.3 多模型协同与证据融合方案 7

1.2.4 技术线路对比与最终选型 8

1.3 核心技术设计与算法优化 9

1.3.1 多格式附件解析与跨页表格恢复 9

1.3.2 Qwen 与 DeepSeek 动态级联抽取 10

1.3.3 提示词优化与原文证据检验 11

1.3.4 OCR 识别修复与字段质量优化 12

1.4 实验结果与技术效果分析 14

1.4.1 Gold50 历史基准测试 14

1.4.2 技术路线实验结果与适用边界 15

1.4.3 难点样本修复前后对比 16

1.4.4 模型调用与附件解析效率分析 16

1.5 技术创新与总结 17

1.5.1 最终方案的技术优势 17

1.5.2 已验收的改进效果与不足 18

2 数据质量分析报告 19

2.1 数据集概况与质量分析目标 19

2.1.1 数据来源与规模 19
2.1.2 数据质量评价方法 20
2.2 数据特征与脏数据分析 21
2.2.1 数据类型与问题分类 21
2.2.2 附件类型与文件格式分布 22
2.2.3 重复文件、嵌套压缩包与长文档 23
2.2.4 扫描污染、跨页表格与字段错位 24
2.3 七字段缺失与错误分析 25
2.3.1 七字段完整率与缺失率 25
2.3.2 高频共同缺失模式 26
2.3.3 Gold50 历史测试误差分析 29
2.3.4 典型字段错误及原因 30
2.4 难点数据修复与迭代效果 31
2.4.1 OCR 坐标修复与表格结构优化 31
2.4.2 69 条扫描明细的前后效果对比 32
2.4.3 典型错误修复 33
2.4.4 修复前后解析耗时分析 34
2.5 数据质量治理与总结 35
2.5.1 原文证据追踪与金额校验 35
2.5.2 异常复核与质量改进机制 36
2.5.3 分析结论与后续优化 37

1 技术路线对比报告

1.1 研究目标与技术方案

1.1.1 赛题要求与实体抽取目标

本项目面向政府采购公告及其附件中的非结构化数据，研究**复杂文档解析**、**实体信息抽取**及**业务关系建模方法**。针对传统招采信息处理过程中依赖人工查阅、字段提取不完整、不同附件信息难以关联等问题，项目设计了从**原始文档解析**到**结构化信息**输出的自动化处理流程，并在此基础上开展知识图谱构建和业务应用。

根据赛题要求，实体抽取任务需要识别产品或服务名称、品目、品牌或明确产品供应商、规格型号、单价、数量、总价七个关键字段。这些信息不仅需要准确提取，还需要与对应公告、采购项目和采购包建立正确关联，以支持后续的供应商分析、采购合作分析和共同竞标分析。

与普通文本信息提取不同，招采公告中的七字段往往具有明显的结构性和业务依赖性。例如，产品名称可能出现在公告正文中，规格型号和价格则保存在报价附件中；同一采购项目可能包含多个采购包，不同采购包又对应不同的供应商和产品明细。如果仅对文本进行关键词匹配或直接生成结构化结果，容易产生字段错位、金额混淆及重复记录。

因此，本项目将实体抽取的研究目标确定为三个方面：

首先，提高复杂文件的解析能力，使系统能够识别不同格式的公告附件，并尽可能恢复扫描表格、跨页明细和不规则文档中的有效信息。

其次，提高七字段抽取的准确性和完整性，通过规则解析与大模型语义理解相结合，识别复杂表述中的产品信息，同时对金额、单位和字段来源进行校验。

最后，增强抽取结果的可追溯性和业务一致性，使每条结构化记录能够保留相应的来源信息，并通过采购包归属、主体角色和金额层级约束，减少无依据补全和错误关联。

项目研究的重点并非单纯增加抽取字段的非空数量，而是在保证原文真实性的前提下，提高有效信息的恢复能力和结构化结果的可靠性。

1.1.2 数据特点与主要技术难点

本项目以赛题公开的 **1038** 篇采购公告为主要研究对象，其**中 970** 篇具有本地配对附件压缩包。对附件进行递归展开后，累计发现 **13018** 次末端文件出现；经过 **SHA256 内容去重**，得到 **7454** 份不同文件内容。最终官方范围的结构化成果包含 **4481** 条产品及服务记录。

原始数据规模较大，且文件类型复杂，包含 **PDF、Word、Excel、HTML** 及**嵌套压缩包**等多种形式。其中，PDF 附件存在明显的长尾分布，部分文件包含大量页面，且可能同时出现采购需求、空白报价模板与实际成交明细。不同结构的信息混杂在同一文档中，增加了产品明细定位和字段抽取的难度。

表 1-1 研究数据规模与实验样本说明

数据类别	数量或规模	主要研究用途
公开采购公告	1038 篇	公告正文解析与结构化建库
本地配对附件包	970 个	多格式附件解析与文件匹配
末端文件出现次数	13018 次	文件格式、递归展开与重复内容分析
去重后的唯一文件内容	7454 份	内容去重与解析缓存研究
可测 PDF 累计页数	53161 页	文档长度分布与复杂附件分析
结构化产品及服务记录	4481 条	七字段覆盖情况及业务结果分析
历史 Gold50 测试集	50 篇、524 条人工标注产品行	产品行及七字段抽取误差评估
扫描表格专项样本	2 份 PDF、69 条产品明细	OCR 与表格解析算法迭代验证
真实模型流程试点	10 篇，其中 6 篇具有完整字段 Gold	模型调用、抽取流程与回退机制验证

结合原始文件盘点和历史抽取测试，项目主要面临以下技术难点。

（1）附件格式复杂，表格结构难以完整恢复。

部分文件存在扩展名与真实内容不一致、多层压缩包嵌套、扫描 PDF 缺少文字层等问题。特别是在跨页表格中，表头可能只出现在第一页，而后续页面继续记录产品明细。如果直接按照页面或文本顺序提取，容易造成产品名称、规格

型号及金额之间的对应关系丢失。

因此，需要在文件识别阶段结合内容签名和递归解析，在表格处理阶段结合文本坐标、表头结构、连续序号和单位信息恢复明细关系。

（2）七字段分布不集中，语义判断与数值提取容易冲突。

同一字段可能出现在公告正文、产品清单及报价附件的不同位置，且字段名称并不统一。例如，“规格参数”“型号规格”等表头可能指向同一字段，而“品目号”与“品目名称”又需要明确区分。

此外，金额字段还存在单位换算、数字识别错误以及预算金额与成交金额混用等问题。纯规则方法难以覆盖所有表达方式，直接使用大模型生成结果又可能出现原文没有的字段或数值改写。

因此，需要将字段语义识别、原始数值提取和业务规则校验分开处理。

（3）抽取结果存在来源与业务归属问题。

招采公告中的企业可能分别承担采购人、中标供应商、参标企业和产品供应商等角色。如果缺少明确的业务约束，容易将中标公司错误填入产品品牌字段，或者将项目金额直接对应到多个产品明细。

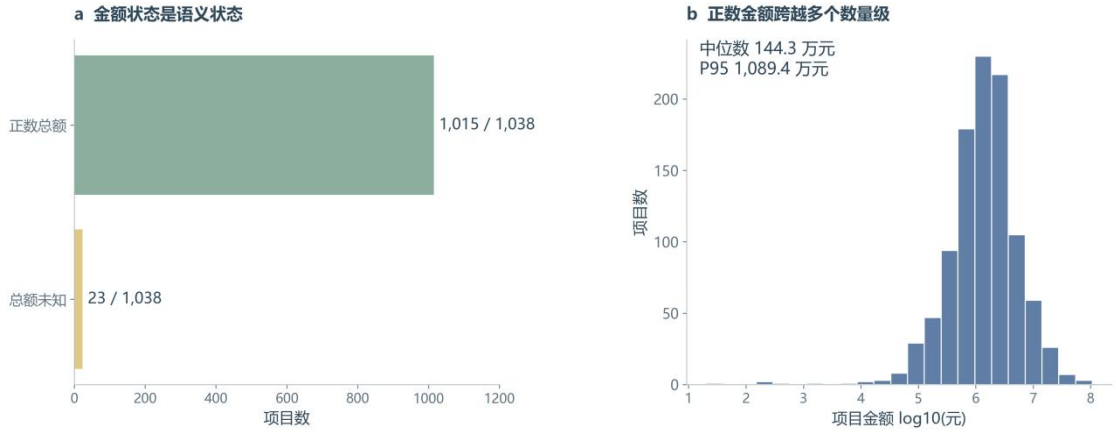


图 1-1 原始采购业务关系与金额信息统计

对此，实体抽取阶段需要保留来源文件、页码和表格行等证据，并结合项目、采购包和主体角色进行约束，为后续关系建模提供可靠输入。

1.1.3 技术路线设计与评价方法

针对上述问题，项目围绕三种实体抽取技术路线开展研究：基于规则与快速表格解析的抽取方案、基于大语言模型的直接抽取方案，以及结合模型语义理解与原文证据约束的融合抽取方案。

规则抽取方案主要依靠表头匹配、正则表达式和单元格映射恢复字段，适用于结构较为规整的报价表；大模型直接抽取方案利用模型理解不同文本表达和字段语义，但需要重点控制字段补全、数值改写和来源不一致等风险；融合方案则将候选提取、模型语义判断、源值投影和规则校验分离，兼顾复杂语义处理与原始数据保真。

为保证技术路线比较具有可解释性，项目从抽取质量、来源可靠性、处理效率和工程适用性四个维度进行评价。

- ✧ 在**抽取质量**方面，分别评价产品行识别和七字段提取效果。通过人工标注结果与自动预测进行匹配，统计正确项、错误项、漏抽项及多余项，并计算 Precision、Recall 和 F1。对于存在字段错位或产品行未对齐的情况，保留相应错误，不以字段非空率代替准确率。
- ✧ 在**来源可靠性**方面，重点检查抽取字段是否能够对应原始文档中的真实位置，是否正确保留单位、金额类型和采购包归属，并区分原文直接值、规则推导值与未知值。对没有明确证据支持的字段，不以模型预测结果直接补全。
- ✧ 在**处理效率**方面，记录附件解析耗时、模型调用次数及相关资源消耗，分析不同方法在复杂文档处理中的实际代价。性能比较以明确的运行条件和处理阶段为基础，避免将单次模型请求耗时与包含 OCR 的完整文件处理时间直接比较。
- ✧ 在**工程适用性**方面，重点评价方法对多格式文件、复杂表格和异常输入的适应能力，以及模型调用失败后的回退能力、结果可复现性和与后续业务模块的衔接情况。

实验采用分层验证方式：通过历史 Gold50 测试分析产品行和七字段抽取误差，通过固定 69 条扫描明细验证 OCR 及表格处理算法的前后变化，并结合真实模型调用记录检查语义映射和流程回退的可执行性。

1.2 实体抽取技术路线对比

针对招采公告中**字段表达不统一**、**表格结构复杂**和**数值容易错位**等问题，项目对三种实体抽取路线进行了比较：**规则与快速表格抽取**、**大模型直接抽取**，以及**模型与原文证据融合抽取**。三种方法各有适用场景，最终方案也结合了实际测试中发现的问题进行选择。

1.2.1 规则与快速表格抽取方案

规则抽取主要通过表头匹配、正则表达式和单元格映射，从公告及附件中提取七字段信息。对于格式规整的报价单，系统可以直接根据表头确定字段位置，读取原始单元格，保留数值、单位和对应行的信息。

在历史 Gold50 流水线中，50 篇公告有 32 篇采用快速表格路径，7 篇采用来源规则路径，两者合计占 78%，其余 11 篇进入模型回退流程，说明规则解析能够承担较多基础处理工作。

但历史测试也暴露了明显的泛化问题。重算 Gold50 的 Precision、Recall 和 F1 分别达到 94.36%、86.93%和 90.49%，而同一历史发布版在独立 Holdout10 上的 Precision 为 83.83%，Recall 仅 22.91%，F1 为 35.99%。

这说明系统虽然能够较准确地识别已经覆盖的字段，但面对新的附件结构时，仍可能遗漏大量真实信息。特别是非标准表头、跨页明细和复杂服务描述，难以完全依赖固定规则处理。

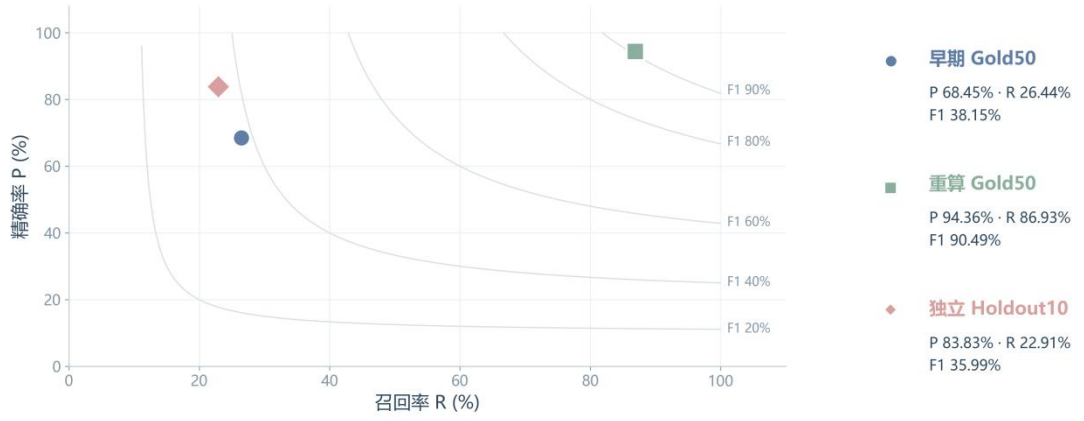


图 1-2 Gold50 历史实验精确率与召回率对比

上图展示了早期 Gold50、重算 Gold50 和独立 Holdout10 的历史测试结果。可以看出，历史流程在已覆盖测试数据上的表现较好，但留出集召回明显不足。因此，项目决定保留规则解析的稳定性，同时引入语义判断，扩大复杂字段的识别范围。

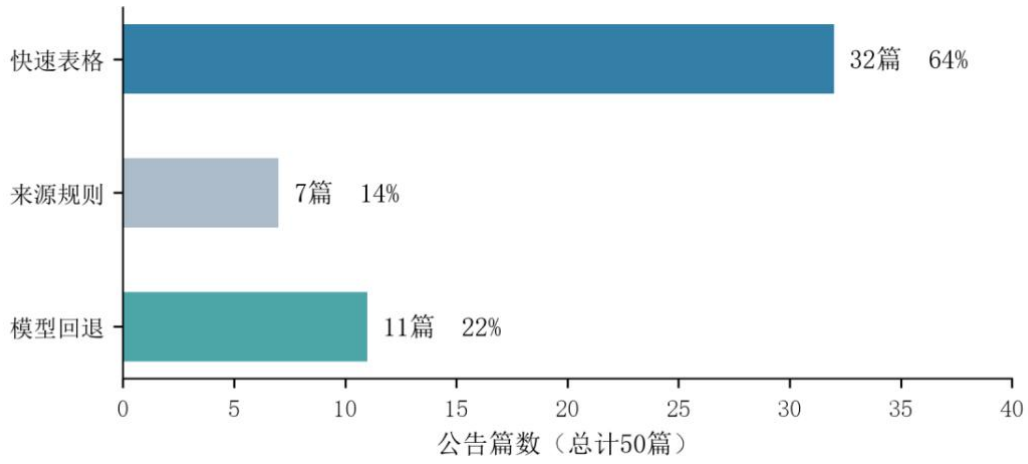


图 1-3 历史 Gold50 公告抽取路径分布

需要说明的是，历史流水线已包含模型回退，上述指标并非纯规则算法的独立成绩；早期与重算 Gold50 还存在对齐口径调整，不能直接视为严格受控的算法增益。

1.2.2 大模型直接抽取方案

大模型直接抽取方案通过提示词理解公告正文和表格内容，并生成七字段结构化结果。与固定规则相比，模型能够识别不同形式的字段表达，更适合处理非标准表头、复杂服务描述和分散在正文中的信息。

为了验证模型的语义理解能力，项目使用 DeepSeek 开发接口开展单表专项实验。模型对一份包含 10 行产品明细的表格进行分析，判断七字段对应的原始列位置，再由程序读取源表中的实际数值。

实验仅进行 1 次真实模型调用，输入 508 个字符、输出 231 个字符，整体耗时约 0.829 秒。最终恢复 10 条产品记录，七字段均通过专项核对。

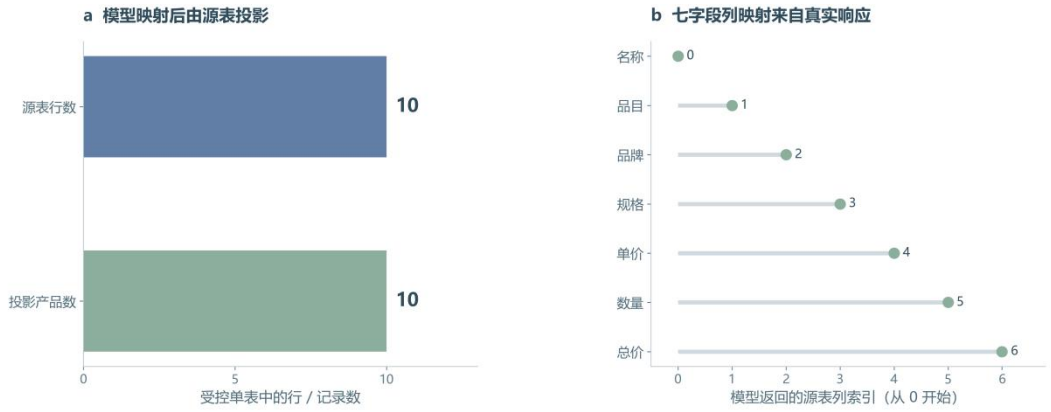


图 1-4 真实模型字段语义映射与原始表格投影实验

这一实验验证了模型识别字段语义的可行性，但也说明仅靠模型生成结果并不充分。对于复杂表格，模型可能出现数值改写、字段错位或无依据补全。例如，将项目预算识别为成交金额，或者把中标供应商误认为产品品牌。

1.2.3 多模型协同与证据融合方案

综合前两种方案的特点，项目最终采用**候选提取、模型语义判断、源值投影和业务校验**相结合的融合路线。

首先，通过文件解析、OCR 和表格结构恢复获取候选信息，并保存对应附件、页码和表格行。随后根据正文与表格的不同特点分配语义处理任务。历史冻结方案采用 Qwen2.5 7B 处理正文、DeepSeek R1 8B 处理表格，模型按照候选条件参与处理，而不是对每份公告固定重复调用。

在字段生成过程中，模型主要负责判断字段含义，程序优先保留原文数值，并进一步通过 JSON Schema、金额算术关系、采购包归属和主体角色规则进行校验。对于缺少明确依据的字段，则保留未知状态，避免错误补全。

在历史来源修正实验中，同一 1038 个项目范围内，采购人关联缺口由 127 项降至 0，无参标记录项目由 371 项降至 0，无有效参标关系项目由 427 项降至 0。

此外，13 组金额归属复核中，有 7 组能够确认分包依据，另外 6 组仍无法证明。38 个算术异常候选经审定后，仍保留 2 处原文数值矛盾及 1 处单位冲突，没有通过强行修改数据来消除异常。

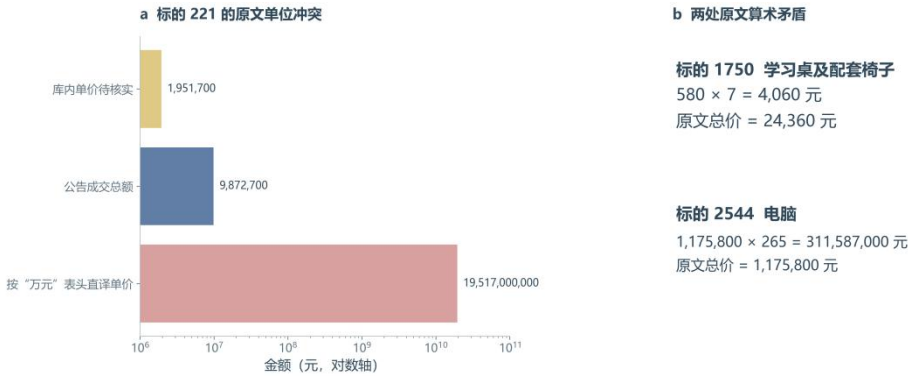


图 1-5 来源约束下的业务结构修正效果

这些实验体现了证据融合方案的优势：不仅能够恢复有明确依据的信息，还能够对来源冲突、金额归属不明等问题保留审计记录，避免错误信息进入后续关系分析。

1.2.4 技术线路对比与最终选型

通过上述研究，三种技术路线的特点逐渐明确。

规则与快速表格抽取能够稳定读取规整表格，保留原始数值和来源位置，但对复杂文本及新附件结构的适应能力有限；大模型能够理解多样化的字段表达，但直接生成结构化结果仍存在字段错位和数值改写风险；证据融合方案则通过技术分工，将模型语义判断与原始数值提取、业务核验结合起来。

	快速表格与规则	纯模型语义抽取	模型与证据融合
现有证据范围	● 历史 39/50 路由	● 受控单表 · 1 次 API	● 1,038 项目来源审计
语义与原文结合	● 固定列与候选规则	● 已验证列语义映射	● 模型响应 + 原文定位
角色与金额准入	◆ 需组合角色/金额校验	◆ 需组合角色/金额校验	● 准入与分包证据约束
同集端到端排名	○ 待同集独立验证	○ 待同集独立验证	○ 待同集独立验证
当前采用位置	■ 保留为候选与基线	■ 保留语义判断能力	■ 选为当前工程方案

实心圆：已有记录或实现 ◆：需组合约束 空心圆：待同条件验证 ■：当前决策

图 1-6 三种实体抽取技术路线的证据与适用性对比

最终选择融合方案，主要基于三个方面：一是保留规则解析的稳定性，减少

不必要的模型调用；二是利用模型理解复杂字段和非标准表格，提高语义适应能力；三是通过原文证据、主体角色和金额约束，降低错误数据进入后续业务分析的风险。

因此，项目形成了**以确定性解析为基础、模型语义判断为补充、来源证据与业务规则为保障**的技术路线。

1.3 核心技术设计与算法优化

1.3.1 多格式附件解析与跨页表格恢复

招采公告的产品信息往往分布在不同格式的附件中，直接按照文件后缀或文本顺序提取，容易出现解析失败、产品行遗漏和字段错位。针对这一问题，项目构建了**真实格式识别、递归解压、内容去重与表格结构恢复**相结合的解析流程。

首先，系统通过文件内容签名判断真实格式，再选择对应解析器，避免将扩展名错误的文件交给不匹配的程序。在原始语料中，共发现 64 次文档扩展名与实际 HTML 内容不一致的情况。对于嵌套 ZIP，系统采用递归展开并保留来源路径，通过 SHA256 摘要识别重复内容，减少相同附件的重复解析。

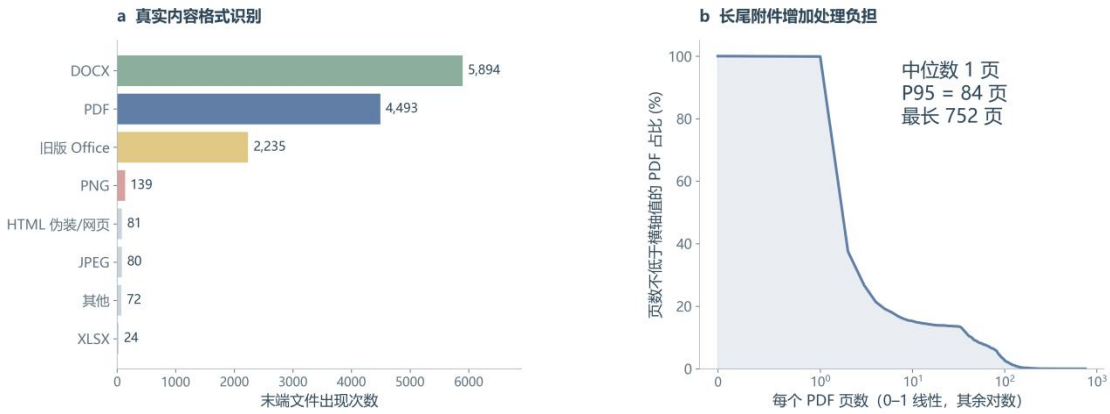


图 1-7 原始文件类型统计与 PDF 页数分布

在表格处理方面，系统不仅提取文字，还保留文本坐标、页面编号和单元格位置。针对跨页报价表，通过比较相邻页面的表头结构，并结合连续序号、列坐标及金额单位，判断表格是否延续，重新建立产品与各字段之间的对应关系。

对于扫描附件，则先检测是否存在可用文字层，再按需执行 OCR 及表格行列恢复。解析时优先识别实际成交明细，避免将采购需求、预算表或空白报价模板误认为最终产品记录。

在一份真实报价附件的专项测试中，系统成功恢复 128 条产品明细，并保留对应来源位置，验证了跨页表格恢复方法的实际可行性。

1.3.2 Qwen 与 DeepSeek 动态级联抽取

完成文档解析后，项目采用**多模型协同与动态路由机制**进行七字段抽取，避免对不同复杂程度的文档采用完全相同的推理方式。

在历史冻结方案中，Qwen2.5 7B 主要承担公告正文中的实体识别与上下文理解，DeepSeek R1 8B 侧重复杂表格的字段语义判断。后续服务器部署采用 Qwen 系列 API 作为主要模型路径，DeepSeek 作为备用及补充处理路径。不同阶段的模型配置分别保存，不混合统计实验结果。

系统首先对解析内容进行候选筛选和结构判断。对于表头明确、字段关系稳定的表格，优先采用确定性映射；对于非标准表头、复杂正文或存在语义歧义的内容，再调用模型完成判断。主路径处理失败或需要进一步确认时，按照路由策略触发备用处理，而不是对所有文档固定重复调用两个模型。

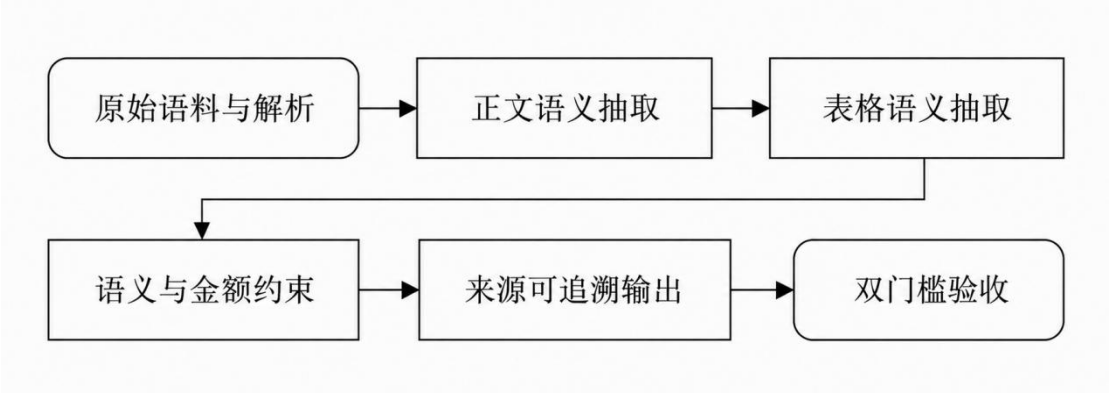


图 1-8 多模型协同抽取与来源校验流程

针对长附件容易超过模型上下文限制的问题，系统进一步引入**布局感知分块、自适应候选组织和提示词压缩**。将公告正文与报价表格分开处理，避免整份长文

档直接输入造成截断，同时保留产品所属的页面、表格和采购包信息。

历史冻结版本中，正文上下文配置为 16384，表格上下文为 8192；表格每批处理 2 个候选区域，并分别设置输出 Token 预算。这些配置主要用于控制长文本输入和模型调用规模，不能直接视为最优参数。

此外，系统记录模型实际参与情况、调用状态及失败回退类型。在 10 篇真实模型流程试点中，8 篇使用了真实模型路径，2 篇通过规则回退完成处理。该结果验证了模型调用与回退机制能够运行，但不将规则回退误计为模型抽取成功。

1.3.3 提示词优化与原文证据检验

为减少大模型直接生成结果时出现的字段错位、数值改写和无依据补全，项目对提示词和输出结构进行了针对性优化。

早期抽取方式主要要求模型生成完整的七字段结果，容易在原文信息不足时产生推测性内容。后续将任务调整为**识别明确事实、判断字段语义、返回对应来源**，并对缺失值和业务字段含义作出明确约束。

对于报价表，模型优先输出各字段对应的列索引或候选位置，再由程序读取原始单元格，而不是重新生成价格、数量等数值。对于公告正文，则要求区分采购人、中标供应商、产品供应商及其他参标主体，避免将不同企业角色混用。

在输出阶段，通过 JSON Schema 约束字段结构，并设置来源证据与业务规则校验。对于原文没有直接公开的字段，保留未知状态；对于可以由金额关系计算得到的数值，单独标记为推导值，不作为原文直接提取结果。

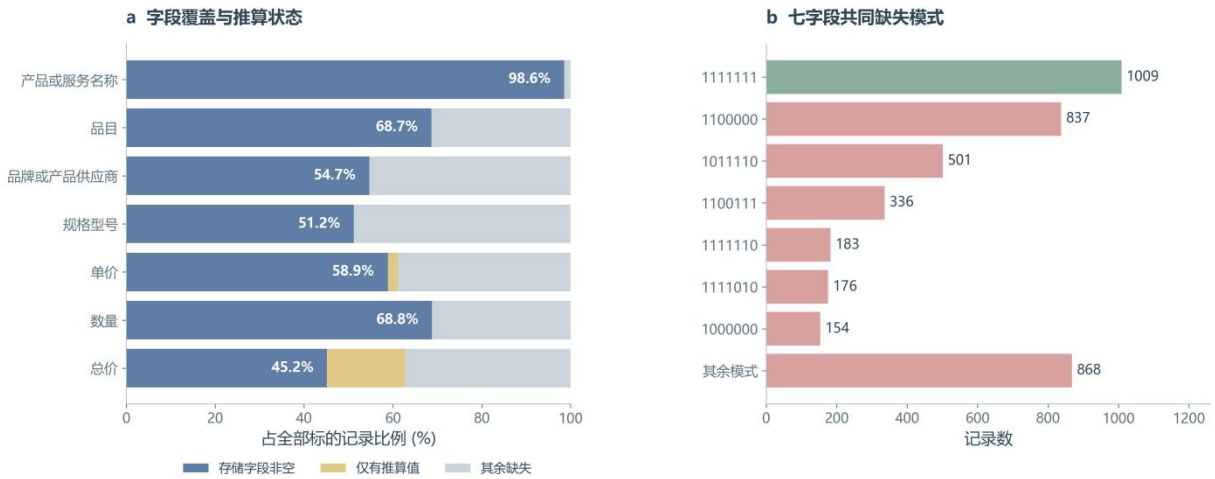


图 1-9 七字段覆盖率与共同缺失情况

例如，某产品的原文单价为 185600 元、数量为 3 台、总价为 556800 元。系统不仅记录七字段信息，还保存来源文件及表格位置，并核对单价与数量的乘积是否与总价一致。

同时，系统对金额类型设置业务约束，明确区分预算金额、项目总额、采购包金额、产品单价和成交总价。对于原文存在的数值冲突，保留原始记录和异常标记，不直接用计算结果覆盖原文。

在历史专项处理中，一份没有成交明细的公告由错误生成 1 条标题伪产品修正为 0 条；另一份多包样本通过跨来源重复行处理，将 20 条重复输出折叠为 9 条。这些结果说明，语义约束与去重规则能够减少部分错误输出，但不能据此认定保留的每条记录均已通过独立人工确认。

1.3.4 OCR 识别修复与字段质量优化

扫描 PDF 是影响产品明细恢复的重要问题。由于部分附件没有可直接读取的文字层，传统文本解析无法获取表格内容，模型也就缺少必要的输入信息。

在两份真实扫描 PDF 专项中，关闭 OCR 时，流程只能从正文得到 2 条占位性产品；启用 OCR 和表格重建后，两个采购包分别恢复 33 条和 36 条产品候选，共 69 条明细。

在进一步的质量检查中，发现整页 OCR 与二次单元格裁剪采用了不同的坐

标缩放方式：整页按照 dpi/72 换算，而局部裁剪曾按照 dpi/96 处理，导致部分字段识别区域发生偏移。

针对这一问题，项目统一了页面渲染与单元格裁剪的坐标换算逻辑，同时对“定制”等中文规格信息增加保护，避免二次识别时由噪声候选覆盖原有正确内容。

为检验修改效果，项目固定两份扫描 PDF 中的 69 条产品明细，保持相同的采购包、产品行和评价规则，对修复前后的结果进行逐字段比较。

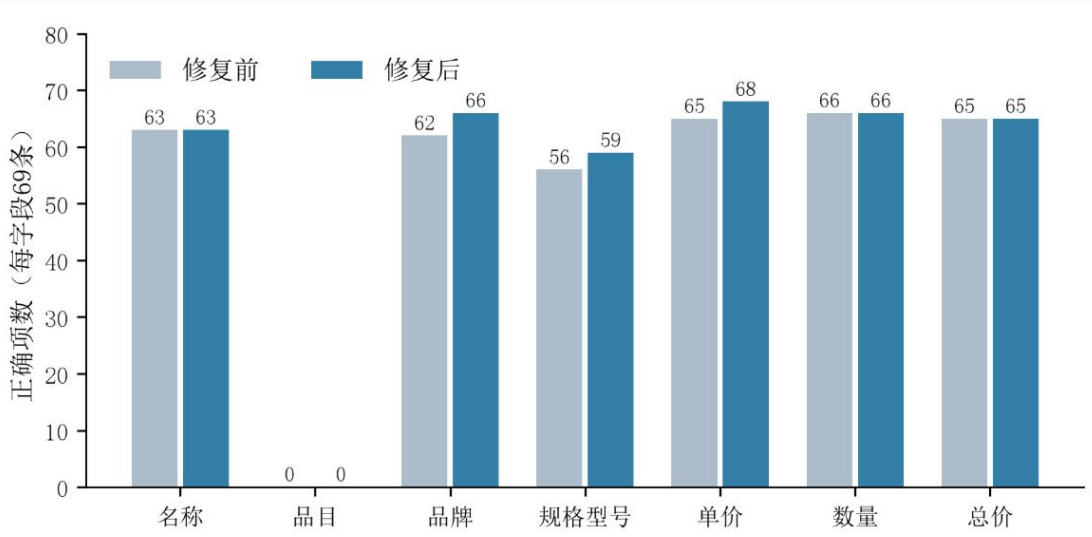


图 1-10 69 条扫描明细修复前后正确项比较

测试显示，品牌正确项由 **62** 条提高至 **66** 条，规格型号由 **56** 条提高至 **59** 条，单价由 **65** 条提高至 **68** 条，分别提升 **5.80**、**4.35** 和 **4.35** 个百分点。名称、数量及总价的正确项数量保持不变，没有因局部优化出现明显退化。

其中，数量字段仍有 3 条无法可靠恢复：两条受到红色印章遮挡，另一条缺少足够的合计金额佐证。系统保留这些异常记录，没有根据人工答案直接补写数值。

在相同两份扫描附件的单轮配对测试中，平均解析耗时由 30.19 秒下降至 28.79 秒，且产品候选数量没有减少。由于每个版本仅进行单轮测量，该结果主要反映本次局部优化的实际表现，不能直接推广为完整模型流水线的稳定提速。

1.4 实验结果与技术效果分析

1.4.1 Gold50 历史基准测试

为检查实体抽取结果与人工标注之间的差异，项目对历史 Gold50 数据进行了固定口径复算。测试集包含 50 篇招采公告、524 条人工标注产品记录，对应保存的自动预测为 497 条。

在产品名称、规格型号及采购包等条件共同约束下，成功匹配 346 条产品记录，另外存在 151 条未匹配预测和 178 条未匹配标注。按产品行计算，Precision 为 69.62%，Recall 为 66.03%，F1 为 67.78%。进一步对七字段进行评价，QA 兼容口径 F1 为 65.39%，严格字段口径 F1 为 64.83%。

表 1-4 Gold50 固定口径复算结果

评价对象	Precision	Recall	F1
产品行	69.62%	66.03%	67.78%
七字段 QA 兼容	67.70%	63.23%	65.39%
七字段严格评价	67.70%	62.19%	64.83%

对字段进一步分析发现，品目的 F1 最低，为 48.73%；名称、品牌和规格型号的F1 分别为 68.86%、68.45%和 69.17%。单价、数量及总价的F1 分别为 68.59%、64.61%和 66.24%。

误差并非均匀分布。在已匹配的 346 条记录中，品目缺失 131 处，其中 130 处集中于同一公告；数量出现 31 处错值和 12 处缺失，部分问题涉及计量单位丢失或不一致。这表明，少量结构特殊的公告可能集中造成大量字段错误，整体指标难以直接反映这些具体问题。

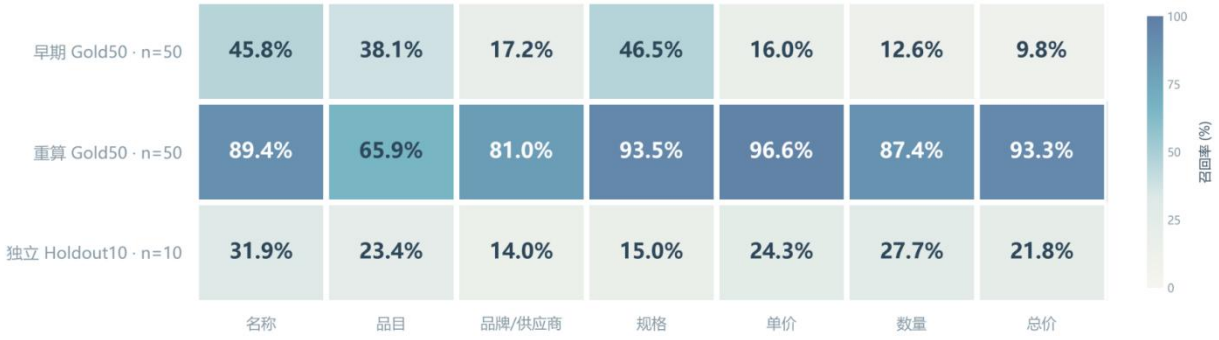


图 1-11 Gold50 各字段历史召回率对比

上述严格复算与此前历史版本的内部评分采用不同对齐规则，不能将两组 F1 直接比较为模型性能变化。通过本次测试，项目明确了后续需要重点检查的品目关联、数量单位和产品行来源问题。

1.4.2 技术路线实验结果与适用边界

在技术路线研究之后，项目进一步采用真实模型试点检验抽取流程是否能够稳定运行，以及保存版本的调整是否真正改善结果。

10 篇试点公告中，8 篇存在真实模型参与，2 篇通过规则回退完成。其中只有 6 篇具备完整的七字段人工标注，因此质量比较以这 6 篇为范围，其余公告仅用于验证处理流程和回退机制。

表 1-5 真实模型试点保存版本对照

指标	修改前	修改后可得版本
产品行 F1	74.50%	74.31%
七字段 F1	76.03%	75.97%
内部综合自测值	71.50%	71.43%

结果显示，修改后可得版本没有带来整体 F1 提升，产品行 F1 下降 0.19 个百分点，七字段 F1 下降 0.06 个百分点。这说明局部规则调整或工程处理成功，并不必然提高最终抽取质量。

需要注意，修改后可得版本并不代表所有样本都完成了修复后的重新推理，其中扫描样本在原试点中还关闭了 OCR。因此，该实验只能说明已有保存结果

尚未证明整体提升，不能据此判断后续 OCR 优化无效。

对于三条技术路线，目前已取得的证据分别覆盖历史处理流程、单表语义映射和实际模型调用，但还缺少相同测试集下的完整受控对照。因此，本阶段将重点放在真实错误定位和可复核的局部效果上，不给出缺乏依据的路线精度排名。

1.4.3 难点样本修复前后对比

针对前文介绍的两份扫描附件，项目将 69 条产品明细作为固定测试对象，对算法修改前后的结果进行逐行核验。测试保持原始文件、产品行和评分规则一致，避免因测试数据变化而影响比较结果。

修复后，品牌正确项由 62 条增加至 66 条，规格型号由 56 条增加至 59 条，单价由 65 条增加至 68 条，分别提高 5.80、4.35 和 4.35 个百分点。

针对字段错位和 OCR 识别污染问题，项目通过原文页码、表格行号及字段来源位置，对异常结果进行追溯和修正。例如，在实际样本中，品牌字段曾被错误识别为“国产 7 楼”，经过原文定位与核验，最终修正为“国产”，避免了无关文字对抽取结果的干扰。

在来源修正后的内部专项诊断中，**七字段整体 F1 达到 89.08%，其中单价、数量和总价三个关键数值字段的专项 F1 达到 96.87%**，表明原文追溯、字段核验与来源修正后的数据具有较好的内部测试表现。需要说明的是，这两项指标基于来源修正后的专项评价口径，包含数据治理与校验环节的作用，并非原始模型的独立盲测成绩，因此不与 Gold50 历史 F1 直接比较。

1.4.4 模型调用与附件解析效率分析

项目分别统计模型调用与附件解析耗时，以判断实际计算开销来自哪些环节。

在 10 篇真实模型试点中，共产生 41 次计费请求，累计输入 114642 个 Token、输出 17226 个 Token，测试环境估算调用费用约 1.10 元。这些数据反映了该批试点的真实调用规模，但由于其中包含规则回退、重试及不同复杂度的公告，不能直接外推为所有公告的固定成本。

附件解析效率使用另外两份扫描 PDF 进行配对测试，统计范围包括文件解析、OCR 识别和表格重建，不包含完整模型推理。

表 1-6 扫描附件修复前后解析耗时

测试附件	修复前	修复后
第 1 包	32.79 秒	31.05 秒
第 2 包	27.59 秒	26.53 秒
平均耗时	30.19 秒	28.79 秒

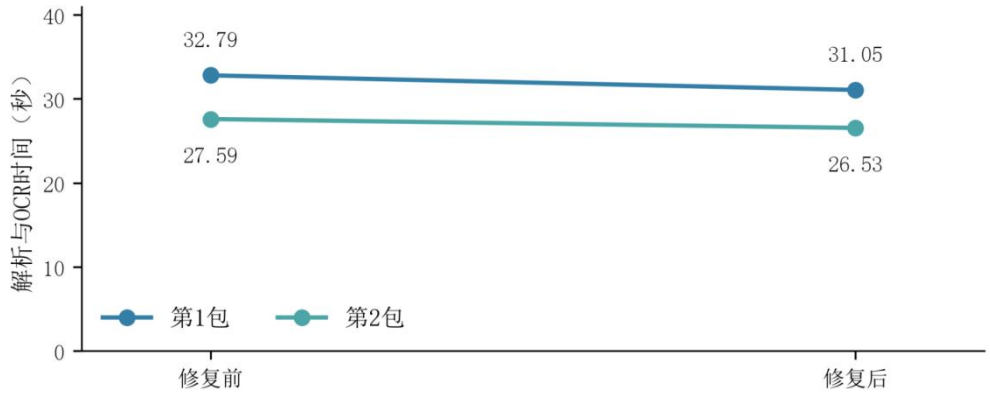


图 1-12 两份扫描附件修复前后解析耗时

两份附件在保留原有产品行数量的情况下，平均解析耗时下降 1.40 秒，约为 4.64%。这一变化说明本次局部处理没有因提高字段识别质量而增加解析耗时。

1.5 技术创新与总结

1.5.1 最终方案的技术优势

本项目针对招采公告来源复杂、字段分散和业务关系容易混淆等问题，构建了融合多格式解析、大模型语义理解和原文证据校验的实体抽取方案。与单纯依靠规则匹配或大模型直接生成的方式相比，系统更注重不同技术之间的协同，在保证信息可追溯的基础上提高复杂数据的处理能力。

技术上的主要改进体现在三个方面。首先，采用布局感知解析与按需 OCR 处理，恢复跨页表格和扫描附件中的产品明细，减少因输入信息缺失造成的漏抽。其次，通过 Qwen 与 DeepSeek 协同处理、动态路由及结构化输出约束，将模型

语义判断与原始数据提取相结合，降低重复推理和数值改写风险。最后，建立字段级来源追踪机制，将抽取结果关联至原始文件、页码及表格行，并结合主体角色、金额类型和算术关系进行校验。

其中，**原文证据约束与模型语义抽取的结合**是方案的重要特点。系统不仅判断字段是否能够提取，还检查提取结果是否具有明确依据。对于金额冲突、主体归属不明或原文未公开的信息，保留异常和未知状态，避免错误数据继续影响知识图谱和业务分析。

1.5.2 已验收的改进效果与不足

从已完成的专项测试来看，项目在复杂附件恢复、字段识别和数据质量校验方面取得了一定效果。针对 69 条扫描产品明细的固定样本，优化后品牌正确项由 62 条增加至 66 条，规格型号由 56 条增加至 59 条，单价由 65 条增加至 68 条。两份扫描附件的单轮平均解析耗时由 30.19 秒降至 28.79 秒，说明本次局部优化在改善部分字段质量的同时，没有增加测试中的解析开销。

在原文追溯与来源修正方面，系统能够定位并纠正部分 OCR 污染和字段错位问题。来源修正后的内部专项诊断显示，**七字段整体 F1 达到 89.08%，单价、数量和总价三个关键字段的专项 F1 达到 96.87%**。这一结果体现了字段校验和数据治理后的质量表现，但由于包含来源修正等处理，不能直接作为原始模型的独立测试成绩。

目前方案仍存在一定不足。一方面，红章遮挡、缺少可靠金额佐证等问题尚未完全解决，部分字段仍需保留空值；另一方面，历史 Gold50 严格复算的七字段 QA 兼容 F1 为 65.39%，10 篇真实模型试点的保存版本也尚未证明整体 F1 提升，说明复杂样本的覆盖和泛化能力仍有改进空间。此外，现阶段缺少三条技术路线在统一测试条件下的完整对照，长期运行效率和最终模型性能仍需进一步验证。

总体来看，本项目已形成较完整的实体抽取与质量控制技术体系，并通过真实样本验证了部分关键算法的改进效果。后续将重点加强复杂附件识别、低置信度字段复核和独立测试集验证，进一步提高系统的准确性、稳定性和实际应用能力。

2 数据质量分析报告

2.1 数据集概况与质量分析目标

2.1.1 数据来源与规模

本项目以赛题提供的政府采购公告及其配套附件为研究对象，重点分析原始数据的完整性、文件结构特征以及实体抽取后形成的结构化数据质量。与前文侧重技术实现不同，本章主要关注数据本身存在的问题，以及这些问题对最终抽取结果的影响。

原始数据包含 1038 篇采购公告和 970 个本地配对附件压缩包。部分公告没有对应的本地附件包，但并不代表原始信息一定缺失，还需要结合公告正文及发布来源判断。

对附件进行递归盘点后，共统计到 13018 次末端文件，按 SHA256 内容摘要去重后为 7454 份独立内容。由于同一文件可能在不同公告或采购包中重复出现，因此文件出现次数与实际独立内容数量并不相同。

结构化成果采用 2026 年 10 月 18 日的官方范围数据快照，共包含 4481 条产品或服务标的、6191 条主体记录及 8684 条原始投标参与记录。数据质量分析主要以 4481 条标的为对象，检查名称、品目、品牌或产品供应商、规格型号、单价、数量和总价七个字段的完整程度及错误情况。

为进一步分析抽取误差，项目同时使用 50 篇公告、524 条人工标注产品记录的历史 Gold50 数据，以及两份扫描附件中的 69 条产品明细，分别开展错误诊断和修复前后对照。

表 2-1 数据集规模与分析对象

数据层次	数据规模	主要分析内容
采购公告	1038 篇	公告来源与附件对应情况
本地配对附件包	970 个	附件覆盖与文件组织
末端文件	13018 次	文件格式、重复和异常情况
去重后独立内容	7454 份	实际独立文件规模

产品或服务标的	4481 条	七字段完整性与缺失情况
主体记录	6191 条	主体信息及角色归属
原始投标参与记录	8684 条	参与信息与业务有效性
Gold50 人工标注	524 条	历史抽取误差分析
扫描专项样本	69 条	难点数据修复效果验证

上述数据分别来自原始文件盘点、结构化成果快照和专项测试，统计对象及时间范围存在差异，不能直接相加或作为同一次实验的结果比较。

2.1.2 数据质量评价方法

本报告从**数据完整性、准确性、一致性、可追溯性及异常处理情况**五个方面评价数据质量，并针对不同层级采用相应的统计方法。

数据完整性主要评价七字段的有值情况。以 4481 条产品或服务标的为统计基础，分别计算各字段的非空数量、缺失数量和缺失率，同时统计七字段全部具有直接值的记录比例。需要区分的是，字段为空可能由原文未公开、实际不适用或抽取遗漏等不同原因造成，因此缺失率反映的是当前数据的有值情况，不能直接视为模型错误率。

准确性主要结合历史人工 Gold 数据进行分析。通过对齐人工标注与系统预测结果，统计正确提取、错误提取、遗漏和多余记录，并计算 Precision、Recall 和 F1。同时，对名称、品牌、规格型号等文本字段进行规范化比较，对价格和数量等数值字段检查实际数值与单位，避免因格式差异影响评价结果。

一致性重点检查同一条记录内部的字段关系，例如数量单位是否匹配、单价与总价是否存在算术矛盾，以及同一采购包内是否出现重复记录。对于原文本身存在冲突的情况，单独标记异常，不直接将其归为抽取错误。

可追溯性主要检查结构化字段能否关联到原始公告、附件、页码及表格行。具有明确来源的位置可以支持后续核查；仅能通过离线匹配推测来源的记录，则作为待确认候选，不计为已经核实的来源。

此外，对于经过修复的难点样本，本报告采用相同原始文件、相同产品行及

相同评分规则开展前后对照，重点观察正确项数量、剩余错误和处理耗时的变化，避免不同测试样本之间的直接比较。

表 2-2 数据质量评价维度与统计方法

评价维度	主要指标	评价依据
完整性	字段完整率、缺失率、共同缺失模式	4481 条结构化标的
准确性	Precision、Recall、F1 及字段错误数量	Gold50 人工标注
一致性	金额算术异常、单位冲突、重复记录	原始字段与业务关系
可追溯性	来源定位情况、待确认与未定位记录	原文及来源引用
修复效果	正确项变化、残留错误、解析耗时	69 条固定扫描明细

通过分层评价，可以分别识别原始数据质量问题、结构化结果中的缺失与错误，以及局部修复取得的实际效果，为后续脏数据分析和质量治理提供依据。

2.2 数据特征与脏数据分析

2.2.1 数据类型与问题分类

招采公告的数据质量问题不仅表现为字段缺失，还涉及文件格式异常、重复附件、表格结构混乱以及业务信息归属不清等情况。部分问题来自原始文件本身，部分则是在信息提取和结构化过程中产生的，需要结合原文进行区分。

根据数据盘点和已有错误记录，项目将脏数据划分为文件异常、结构异常、字段异常和业务语义异常四类。

表 2-3 主要脏数据类型及表现

问题类别	典型表现	对数据质量的影响
文件异常	文件扩展名与实际格式不符、附件损坏、缺少可读文字层	文件无法正常读取，造成信息缺失

结构异常	嵌套压缩包、重复附件、跨页表格、合并单元格	产品记录重复或字段对应关系错乱
字段异常	OCR 乱码、单位丢失、数字位数错误、字段空缺	产品属性和金额不准确
业务语义异常	供应商角色混淆、预算与成交金额混用、采购包归属不明	错误关联企业、产品或交易金额

这些问题往往同时存在。例如，一份扫描报价表可能既包含跨页明细，又存在印章遮挡；同一个产品也可能同时出现在采购需求表和成交结果表中。如果只根据文字是否出现判断数据质量，就容易将重复记录误认为新增产品，或者把原文没有公开的信息当作抽取遗漏。

因此，本报告将文件自身异常、结构化结果错误和原文未公开的信息分别统计。对于无法确认的字段，保留缺失或待核查状态，不直接认定为错误数据。

2.2.2 附件类型与文件格式分布

原始附件具有明显的格式多样性。对 13018 次末端文件进行内容识别后发现，DOCX、PDF 和旧版 Office 文档占据绝大部分，同时存在图片、HTML 及电子表格等其他格式。

表 2-4 原始附件真实内容格式分布

文件格式	出现次数	占比
DOCX	5894	45.28%
PDF	4493	34.51%
旧版 Office	2235	17.17%
PNG	139	1.07%
HTML	81	0.62%
JPEG	80	0.61%
XLSX	24	0.18%
其他	72	0.55%
合计	**13018**	**100%**

从分布来看，DOCX 占比最高，其次为 PDF 和旧版 Office 文档，三者合计

达到 96.96%。这说明大部分采购信息以办公文档形式保存，但不同格式之间的内容组织方式存在差异，直接影响后续字段获取和核查。

此外，原始语料中发现 64 次文件扩展名显示为办公文档、实际内容却为 HTML 的情况。这类异常说明文件名并不能完全反映文件内容。如果仅按扩展名统计或处理，可能造成格式分类错误，甚至将可读取的信息误判为损坏文件。

需要说明的是，本节统计的是文件出现次数，并未对相同内容进行去重，因此不能直接将 13018 次理解为 13018 份不同的采购附件。

2.2.3 重复文件、嵌套压缩包与长文档

在原始附件盘点中，重复内容是比较突出的数据特征。递归展开后，共发现 13674 个成员节点，其中包含 656 个压缩容器节点和 13018 次末端文件，压缩包最大嵌套深度为 3 层。按文件内容摘要进行去重后，仅保留 7454 份独立内容，其余 5564 次属于内容重复出现，重复比例达到 42.74%。

这一现象说明，同一文件可能被不同公告或采购包反复引用。重复内容会增加处理工作量，但不一定属于无效数据。例如，同一份报价附件可能与不同采购包存在独立的来源关系，因此不能简单删除所有重复文件，而应区分内容重复与业务记录重复。

另一个明显特征是 PDF 长度差异较大。在 4493 次 PDF 出现记录中，4492 次能够读取页数，累计 53161 页；另外存在 6 次零页 PDF 和 1 个无法读取页数的损坏文件。

可测 PDF 的页数中位数为 1 页，95 分位数达到 84 页，最长附件为 752 页。其中，0～1 页的 PDF 有 2806 次，2～20 页的有 1062 次，21 页及以上的有 624 次，占可测 PDF 的 13.89%。

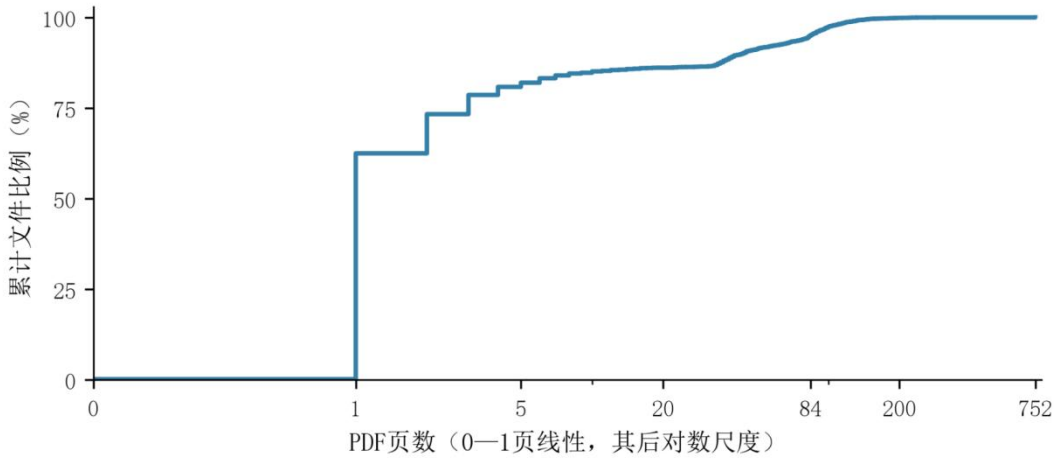


图 2-1 PDF 附件页数经验累积分布

从图 2-1 可以看出，PDF 页数呈现明显的长尾分布：大多数附件篇幅较短，但少量超长文件包含大量表格和说明内容。这些长文档更容易出现报价明细跨页、表头重复以及采购需求与成交结果混排等情况，也增加了人工核查的难度。

因此，在后续数据质量统计中，需要将长附件单独标记，不能仅依据文件成功打开或提取到文字，就认定其中的产品明细已经完整获取。

2.2.4 扫描污染、跨页表格与字段错位

除文件格式和长度差异外，原始附件中还存在扫描质量不稳定、表格结构不完整及字段位置混淆等问题。这些问题虽然未必导致整份文件读取失败，却可能直接影响产品记录的准确性。

扫描污染主要表现为文字模糊、印章遮挡、字符粘连和数字识别错误。部分 PDF 没有可直接读取的文字层，产品名称、型号、数量及金额只能从页面图像中获取。当表格线条与文字相互干扰时，容易出现相邻单元格内容混入同一字段的情况。

跨页表格则主要影响记录的连续性。一些报价明细分布在多个页面，后续页面只保留产品行，不再重复完整表头；另一些表格存在合并单元格，导致产品名称、品牌和金额的对应位置不够明确。如果没有正确识别表格结构，同一产品可能被拆分成多条记录，也可能出现不同产品之间的字段串行。

在已有数据检查中，还观察到**品牌字段混入无关文字**、**规格型号末尾字符缺失**，以及**金额数字位数识别错误**等问题。这类错误具有一定隐蔽性：字段本身并不为空，但保存的内容与原文不一致，仅通过字段完整率难以发现。

另外，采购公告经常同时包含采购需求、预算说明和最终成交信息。即使金额识别正确，如果未区分其对应的业务含义，也可能将预算金额填入产品成交总价，或者把采购包金额错误分配给单个产品。

综合来看，原始数据中的问题既包括可以直接统计的文件异常，也包括需要结合原文才能发现的字段和业务错误。前者可通过格式、重复率和页数分布进行量化，后者则需要结合人工标注及真实样本开展进一步核查。下一节将从七字段缺失情况入手，分析这些问题在结构化结果中的具体表现。

2.3 七字段缺失与错误分析

2.3.1 七字段完整率与缺失率

为了解结构化成果中各字段的信息覆盖情况，项目以 4481 条产品或服务标的为统计对象，对名称、品目、品牌或产品供应商、规格型号、单价、数量和总价进行逐字段检查。

统计时，空字符串以及“未公开”“不适用”等占位内容统一视为缺失；数值零保留为有效值。由其他字段计算得到的单价或总价单独记录，不计入原文直接值的完整率。

表 2-5 七字段直接值完整性统计

字段	有值条数	缺失条数	完整率
名称	4426	55	98.77%
品目	2713	1768	60.54%
品牌或产品供应商	2705	1776	60.37%
规格型号	2626	1855	58.60%
单价	3031	1450	67.64%
数量	3424	1057	76.41%
总价	2530	1951	56.46%

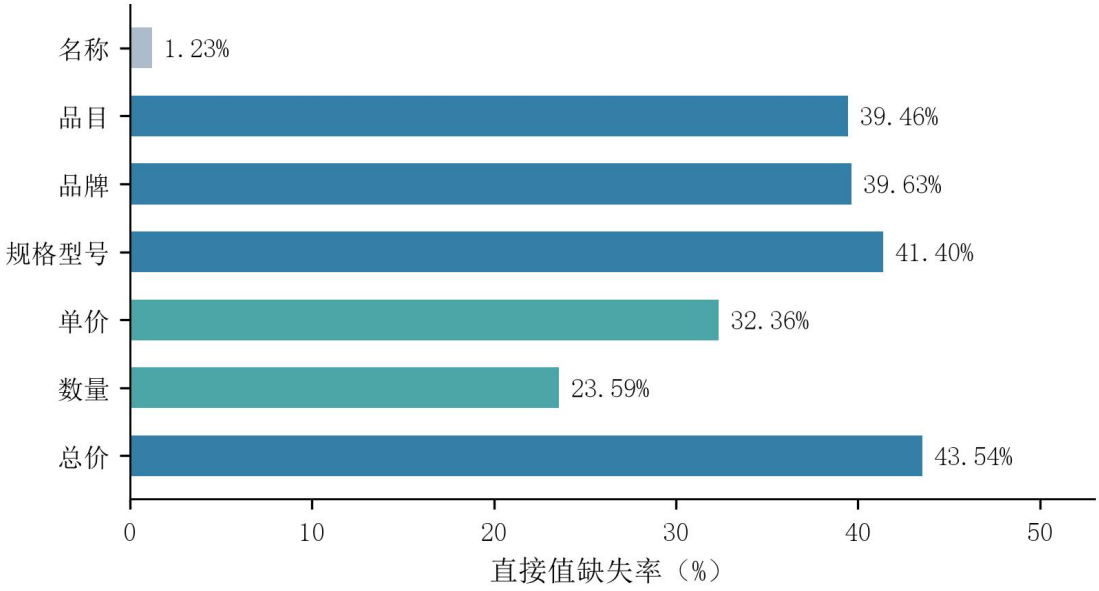


图 2-2 七字段原文直接值缺失率

从统计结果来看，名称字段完整率最高，达到 98.77%，说明大部分记录已经具有基本名称信息。但名称存在并不代表整条产品信息完整，也无法单独证明其与原文对应正确。

相比之下，规格型号、品牌和品目的缺失率分别达到 41.40%、39.63%和 39.46%。其中，总价缺失 1951 条，缺失率为 43.54%，是七字段中缺失比例最高的字段。

从整条记录来看，七字段同时具有直接值的标的仅 1297 条，占全部标的的 28.94%；其余 3184 条至少缺少一个字段。这说明结构化结果虽然具备一定的信息覆盖规模，但字段完整程度仍存在明显差异。

需要注意，缺失并不全部代表抽取失败。服务类标的可能没有独立品牌或规格型号，部分公告也没有公开单项成交价格。因此，完整率主要用于描述当前数据状态，具体缺失原因还需结合原文进一步判断。

2.3.2 高频共同缺失模式

单独统计各字段的缺失率，只能反映哪些字段容易为空，却无法说明这些缺失是否集中出现在同一批记录中。为此，项目进一步统计了每条标的的缺失字段

数量及共同缺失组合。

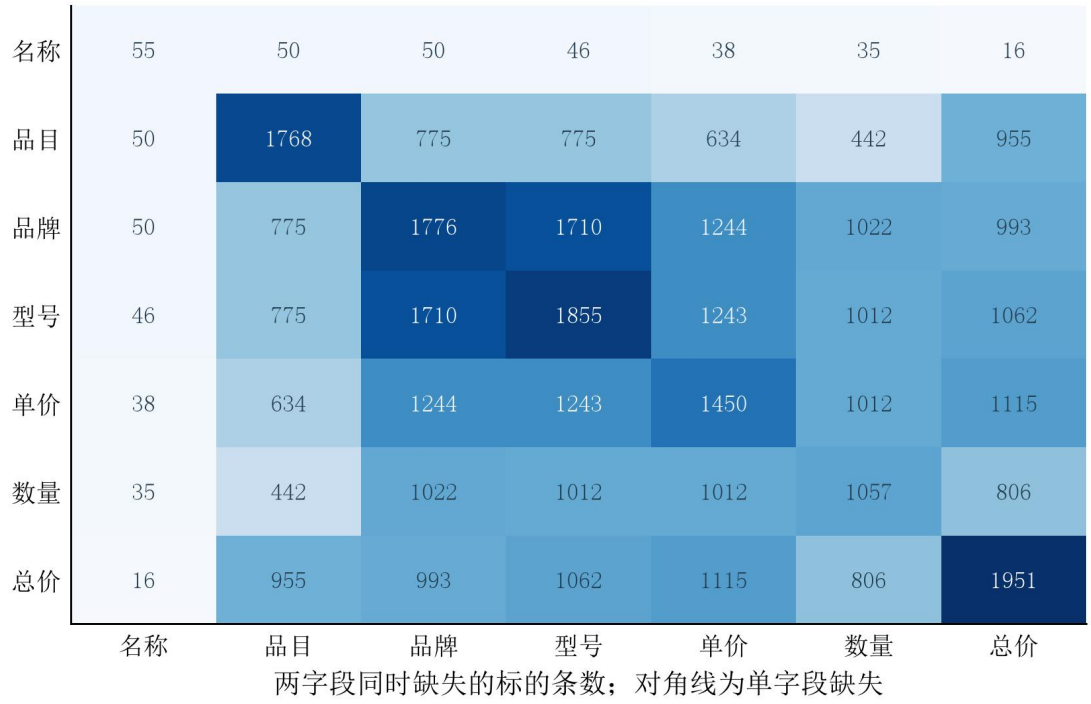


图 2-3 单条标的缺失字段数量分布

统计发现，七字段全部有值的记录为 1297 条；缺少 1 个字段的有 577 条，缺少 2 个字段的有 1114 条，缺少 5 个字段的有 883 条，缺少 6 个字段的有 225 条，没有出现七字段全部缺失的记录。

其中，缺少 2 个字段和 5 个字段的记录数量相对突出，说明数据完整性问题并非完全随机分布，而是存在一定的组合特征。

进一步按照精确缺失组合进行统计，得到以下高频模式。

表 2-6 高频共同缺失组合

缺失字段组合	标的条数	占比
品牌、规格型号、单价、数量、总价	557	12.43%
品目、总价	540	12.05%
仅品目	385	8.59%
品牌、规格型号	341	7.61%

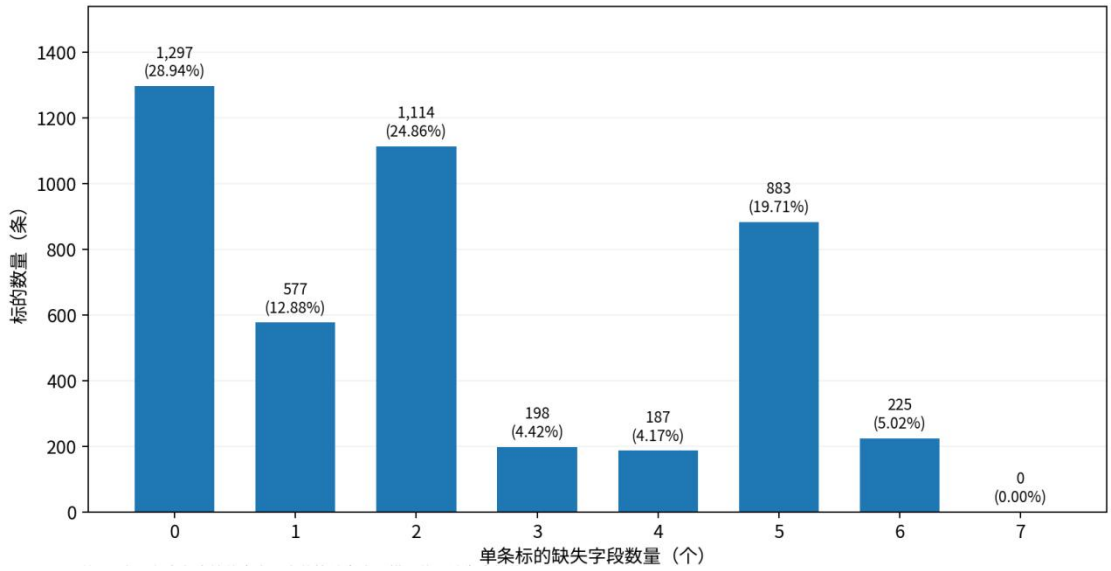


图 2-4 高频共同缺失字段组合统计

例如，557 条记录同时缺少品牌、型号和三个数值字段，说明这部分记录虽然具有产品或服务名称等基本信息，但缺少能够支持明细分析的关键属性。此类情况需要检查原文是否只有服务总包描述，或者产品明细尚未被完整获取。

另外，540 条记录同时缺少品目和总价，385 条记录仅缺品目。这两种模式合计较多，提示品目信息可能存在公告级共享、表格合并或未正确对应到产品行等情况。

为了进一步观察字段之间的关联，项目还统计了任意两个字段同时缺失的次数。

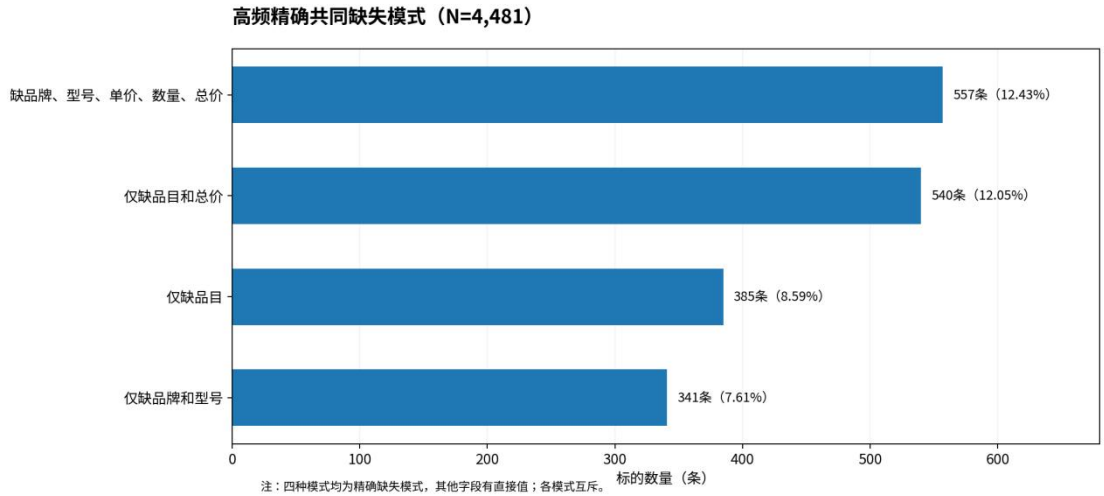


图 2-5 七字段两两共同缺失关系

从共同缺失矩阵可以更直观地观察哪些字段经常同时为空。但共同缺失只能说明统计关联，不能直接证明具体原因。例如，品牌与规格型号同时缺失，可能属于服务类项目本身不适用，也可能是原始报价表没有被完整提取。

因此，后续质量检查需要根据公告类型、附件内容和原文证据进行分类，而不能对所有缺失组合采用统一补值规则。

2.3.3 Gold50 历史测试误差分析

字段有值统计能够反映完整程度，但无法直接判断已填写内容是否正确。为此，项目结合 Gold50 人工标注结果，对历史保存的预测数据进行进一步分析。

Gold50 包含 524 条人工标注产品记录，系统保存预测 497 条。按照名称、型号及采购包等条件进行严格匹配后，成功对齐 346 条产品记录。

在七字段层面，历史诊断共统计正确字段 2046 项、错值 54 项、缺失或未对齐 1190 项，以及多余或未对齐 922 项。由于部分产品尚未成功建立身份对应关系，缺失和多余类别中包含未对齐情况，不能全部直接认定为真实漏抽或误抽。

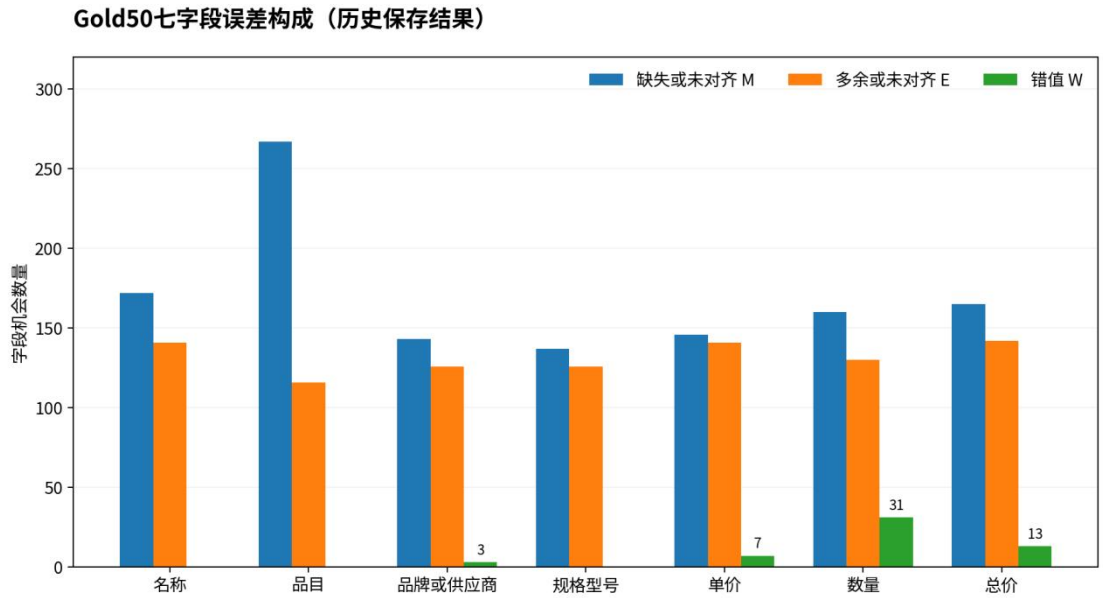


图 2-6 Gold50 七字段抽取错误构成

从已对齐字段中的错值情况来看，数量错误最为突出，共 31 处；总价错误 13 处，单价错误 7 处，品牌或产品供应商错误 3 处。

从缺失或未对齐情况来看，品目达到 267 项，是七字段中最明显的薄弱项。此外，规格型号、品牌和金额字段也存在一定数量的缺口。

进一步检查发现，在已匹配的 346 条产品记录中，品目缺失 131 处，其中 130 处集中于同一公告。这说明部分异常具有明显的样本集中性，可能与公告内部共享品目信息没有正确关联到产品明细有关，而不是每条记录都发生独立的识别错误。

此外，497 条保存预测中有 205 条缺少来源引用，占 41.25%。缺少明确来源的记录难以进一步核查字段与原文的对应情况，也增加了错误归因的难度。

综合来看，历史误差主要集中在产品来源与身份对应、共享品目信息缺失以及数量单位和金额识别等方面。相比单纯增加输出字段，更需要检查字段是否来自正确的产品行，以及数值是否保留了原始单位和业务含义。

2.3.4 典型字段错误及原因

为了更清楚地解释上述统计结果，项目从历史 Gold50 和扫描附件中选取了几类具有代表性的错误记录，对原文信息与保存预测进行对照。

表 2-7 典型字段错误案例

样本位置	原文或人工标注	存在问题	主要原因
Gold14 / id194	其他信息化设备	大量产品品目为空	同一公告内共享品目未正确关联
Gold01 / id34	天地伟业、TC-P813WT	品牌乱码、型号字符缺失	扫描文字污染与字段裁剪问题
Gold14 第 29 行	单价 7000 元	预测为 70000 元	数字位数识别错误
Gold31 部分记录	1495000 元、180000 元	原文金额单位未正确保留	“万元”与“元”换算关系混淆
第 2 包扫描明细	数量区域被红章遮挡	数量无法可靠确定	原文局部信息受损

这些错误可以归纳为三类。

第一类是字段信息存在，但没有正确分配到产品记录。例如，部分公告使用合并单元格或统一品目描述，只有表格首行明确给出品目名称，其余产品通过表格结构共享该信息。如果只检查单条产品所在行，就容易造成大量品目缺失。

第二类是原文字符识别错误。品牌、型号和金额可能因为扫描模糊、字符粘连或邻近文字干扰而出现异常。例如，已有来源核查案例曾将品牌字段识别为“国产 7 楼”，经过原文定位后修正为“国产”。这类错误虽然字段非空，却会影响检索和后续数据统计。

第三类是单位及金额关系错误。例如，将 7000 元误写为 70000 元，或者在“万元”与“元”之间丢失换算关系，会直接改变数值含义。由于错误值仍然属于合法数字，仅依靠非空检查无法发现。

对于红章遮挡、原文数值矛盾和确实未公开的信息，则不能简单认定为空值错误。这类记录需要保留原始证据及异常状态，避免通过猜测补全形成新的不准确数据。

总体而言，七字段质量问题既包括明显的字段缺失，也包括更难发现的错值、单位变化和来源对应错误。缺失率统计能够帮助定位重点字段，而 Gold50 及原文案例则进一步说明了错误发生的位置和表现形式，为后续难点样本修复与数据质量治理提供依据。

2.4 难点数据修复与迭代效果

2.4.1 OCR 坐标修复与表格结构优化

在前面的数据质量分析中，扫描污染、字段错位和表格结构不完整是影响产品明细准确性的重要因素。针对这些问题，项目选取具有代表性的扫描附件进行逐行检查，重点分析字段值与原始单元格不一致的情况。

检查发现，部分识别结果虽然能够提取到文字，但实际位置与原始表格存在偏移。例如，品牌字段可能混入相邻文字，规格型号末尾字符可能被截断，价格字段也可能因裁剪位置不准确而遗漏数字。

进一步排查发现，整页图像与局部单元格使用的坐标缩放比例不一致，是造成部分错位的重要原因。修复后，项目重新核对了字段对应的原始位置，并对容易受到噪声干扰的中文规格信息进行保护，避免已有正确值被错误候选覆盖。

对于跨页表格，质量检查重点关注产品序号是否连续、记录是否重复以及金额是否对应正确的产品行。在两份真实扫描附件中，系统分别恢复了 33 条和 36 条产品候选，共 69 条明细，并保留各自的采购包和来源位置。

这一阶段的主要成果是改善了部分字段与原始表格的对应关系，为后续逐字段质量核验提供了更完整的数据基础。

2.4.2 69 条扫描明细的前后效果对比

为检验修复效果，项目以相同两份扫描 PDF 中的 69 条产品明细作为固定样本，保持采购包、产品序号和评价规则不变，对修复前后的结果进行逐字段比较。

表 2-8 69 条扫描明细修复前后质量对比

字段	修复前正确	修复后正确	修复后正确比例
名称	63	63	91.30%
品目	0	0	0.00%
品牌	62	66	95.65%
规格型号	56	59	85.51%
单价	65	68	98.55%
数量	66	66	95.65%
总价	65	65	94.20%

对比结果显示，品牌正确项增加 4 条，规格型号和单价分别增加 3 条，对应正确比例提升 5.80、4.35 和 4.35 个百分点。

名称、数量及总价保持稳定，说明此次修复主要改善了部分字段的识别质量，并没有通过降低其他字段要求获得表面提升。

需要特别说明的是，品目字段仍为 0 条正确。这是因为本次实验只针对快速

OCR 表格处理结果进行检查，没有包含完整平台的语义补充环节，因此不能将这一数据直接视为系统最终品目识别水平。

此外，**69 条产品候选被恢复，不等于 69 条产品的七字段全部正确**。本次评价采用逐字段核验方式，分别记录改善和未改善的结果，使实验结论更加明确。

2.4.3 典型错误修复

除整体统计外，项目还保留了具体异常记录，结合原始页面检查错误原因及最终处理状态。

在品牌识别方面，曾出现将“国产 7 楼”整体写入品牌字段的情况。通过原文定位确认，“7 楼”属于无关内容，最终将品牌修正为“国产”。这一案例反映出，字段非空并不代表其内容正确，尤其是表格邻近文字可能对 OCR 结果造成污染。

在数值识别方面，历史 Gold50 中存在将 7000 元误识别为 70000 元的案例。由于错误数字仍然符合金额格式，单纯检查字段是否为空无法发现问题，需要结合原始报价表及金额关系进一步核查。该案例在历史记录中已被定位，但不能据此认定所有同类错误均已修复。

更典型的问题出现在扫描附件的数量字段。第 2 包第 6 行和第 7 行受到红色印章遮挡，其中第 6 行对应的产品为电脑麦克风，印章覆盖了部分数量及金额区域。

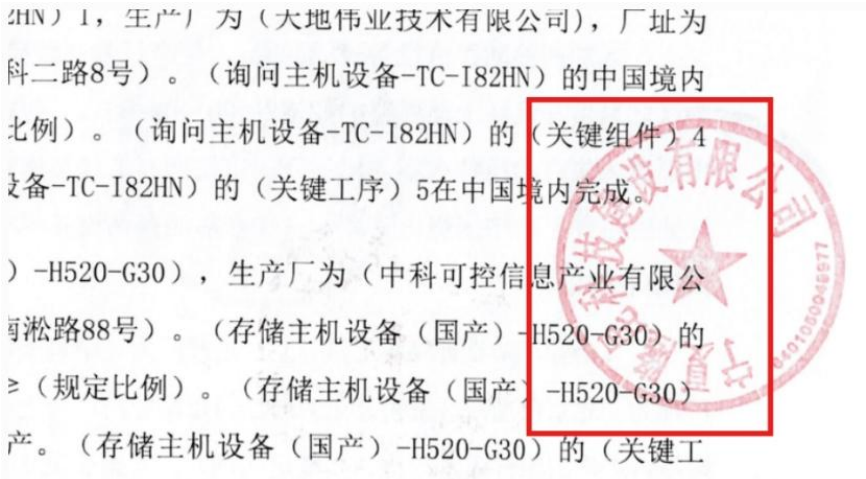


图 2-7 扫描附件印章遮挡造成的字段识别问题

项目对这类记录尝试了原图核查、灰度处理、对比度调整和局部放大，但仍无法获得足够稳定的自动识别结果。第 2 包第 23 行虽然能够得到数量候选，但缺少可靠的合计金额佐证，也未直接采用该候选值。

因此，上述 3 条数量信息最终继续保留为空值，并记录对应采购包、页面和产品行，供后续人工核查。

这些案例说明，数据质量修复不能只追求字段非空数量的增加。对于原文信息不完整或存在明显冲突的情况，保留真实的不确定状态，比填入缺少依据的数值更有利于保证数据可靠性。

2.4.4 修复前后解析耗时分析

在检查字段质量变化的同时，项目对相同两份扫描附件进行了修复前后的配对耗时测试，以观察质量改进是否带来明显的额外处理开销。

本次统计包含 PDF 读取、OCR 识别及表格重建，不包含完整模型推理和数据库入库过程。

表 2-9 两份扫描附件修复前后耗时对比

测试对象	修复前	修复后	减少耗时
第 1 包（33 条）	32.79 秒	31.05 秒	1.74 秒
第 2 包（36 条）	27.59 秒	26.53 秒	1.06 秒
平均耗时	30.19 秒	28.79 秒	1.40 秒



图 2-8 扫描附件修复前后解析耗时比较

从测试结果来看，两份附件的解析耗时均有所下降，平均耗时由 30.19 秒减少至 28.79 秒，降幅约为 4.64%。

结合前面的字段质量对比，可以看到此次局部修复在改善品牌、规格型号和单价正确项数量的同时，保留了原有 69 条产品候选，没有因减少识别内容而获得耗时优势。

不过，每份附件在每个版本下仅进行了单次测量，因此上述结果只能说明本次配对测试中的耗时变化，不能直接推断长期运行的稳定提速比例。

总体来看，本轮难点数据修复取得了可以逐行核查的局部改善，同时也保留了品目未恢复、数量受遮挡和金额证据不足等问题。后续数据质量治理应继续关注未解决字段及其原文证据，而不是仅以字段填充数量衡量修复成效。

2.5 数据质量治理与总结

2.5.1 原文证据追踪与金额校验

通过前面的数据质量分析可以发现，字段完整并不代表内容准确。部分产品虽然已经提取出名称、品牌和金额，但仍可能存在来源位置不明确、金额类型混淆或采购包归属错误等问题。因此，数据质量治理除了关注字段是否有值，还需要检查每条记录是否具有可靠的原文依据。

在 4481 条结构化标的中，3486 条保存了来源引用，995 条缺少持久化来源信息。针对缺失记录开展离线匹配后，找到 177 条可能对应原文的候选记录，仍有 818 条尚未定位。由于这 177 条尚未经过逐条确认，因此只能作为待核查线索，不能直接视为来源验证成功。

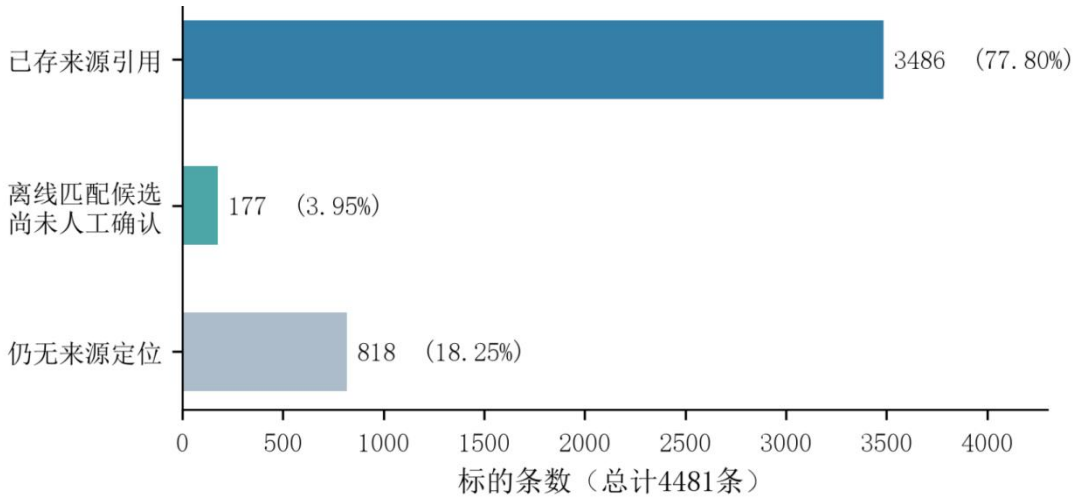


图 2-9 结构化标的原文来源定位情况

原文追踪不仅需要记录公告或附件名称，还应尽可能明确对应的采购包、页面及表格行，并检查引用内容是否真正支持字段取值。对于同一附件中存在多个采购包或产品明细的情况，不能仅凭文件来源相同，就认定字段归属一定正确。

金额质量同样需要单独检查。采购公告中的预算、单价、产品总价和采购包总额具有不同含义，如果直接混合使用，可能造成成交金额统计偏差。

在现有 4481 条标的中，有 105 条记录仅存在推导单价而没有原文直接单价，726 条记录仅存在推导总价而没有原文直接总价。虽然这些计算结果能够辅助金额核验，但不能计入直接提取字段的完整率。

对于存在算术矛盾的原始数据，项目保留原文金额及异常状态，不直接使用计算值覆盖。例如，部分历史记录出现单价与数量乘积不等于原文总价的情况，此时需要进一步核查是否存在单位、采购包或金额含义差异。

通过区分直接值、推导值和待核查值，可以避免因自动补全而提高表面完整率，使最终数据更符合原始公告的实际情况。

2.5.2 异常复核与质量改进机制

结合七字段缺失分布、Gold50 历史误差和扫描附件专项测试，项目对需要继续处理的质量问题进行了分类，并根据影响程度安排复核顺序。

对于来源缺失的记录，优先检查原始公告与附件的对应关系，逐步补充可核查的页面和表格位置；对于品目集中缺失的情况，重点检查同一公告或采购包内是否存在共享品目信息，避免在缺少依据时跨包填充。

对于数量和金额异常，则重点核查原始单位、数字位数和算术关系。特别是金额数量级明显异常、单价与总价不一致以及同一金额涉及多个供应商的记录，需要结合原文进一步判断。

扫描污染和遮挡问题采取不同处理方式。能够通过原图确认的错误，可以在保留原值及修正记录的前提下更新；对于红章覆盖、文字无法辨认或证据不足的字段，则继续保留未知状态，不根据其他样本进行猜测。

表 2-10 数据质量问题及后续复核重点

质量问题	优先复核范围	核查依据
来源缺失	995 条缺少持久化来源的标的	原始文件、页面及表格行
来源待确认	177 条离线匹配候选	原文是否支持对应字段
品目缺失	同一公告集中缺失的产品行	共享品目与采购包对应关系
数量及金额异常	单位丢失、数字污染、金额冲突	原始数值、单位及算术关系
扫描污染	红章遮挡、字符混入、字段截断	原始扫描页面
主体归属异常	供应商角色或采购包不明确的记录	公告结果、主体角色和包级证据

在质量改进过程中，每条异常记录应尽量保留问题类型、原始值、修正值、来源位置和复核结果。对于已经完成核查的记录，可以重新统计相关字段的质量变化；对于尚未确认的问题，则维持待核查状态，避免将处理完成数量直接等同于正确数量。

此外，现有 Gold50 可继续作为历史误差检查依据，但应增加新的独立复核样本，重点覆盖复杂服务类项目、长表格、多采购包以及存在金额歧义的公告，以检查改进措施对新数据是否同样有效。

2.5.3 分析结论与后续优化

本报告围绕原始附件、结构化标的、人工标注和扫描专项四个层次，对项目数据质量进行了系统分析。

从原始数据来看，文件重复、格式差异和 PDF 长度不均衡是较为明显的特征。13018 次末端文件中有 5564 次重复出现，重复比例达到 42.74%；部分附件还存在扫描污染、跨页表格和文件格式异常等情况，增加了数据核查难度。

从结构化结果来看，4481 条标的中，七字段直接值全部齐备的有 1297 条，占 28.94%。品目、品牌、规格型号和总价等字段的缺失相对集中，部分记录还存在多字段共同缺失的情况。这说明后续质量治理需要关注字段之间的关联，而不能仅依靠单字段补全。

从历史误差来看，Gold50 揭示了品目集中缺失、数量单位错误和产品来源对应不足等问题。固定 69 条扫描明细的专项测试进一步验证，局部修复能够改善品牌、规格型号和单价的识别结果，但仍存在品目未恢复、数量遮挡无法确认等情况。

总体而言，项目已能够通过实际统计和原文核查识别主要数据质量问题，并对部分难点样本取得可验证的改善。但现阶段仍不能准确判定每一个缺失字段的具体原因，部分来源定位和金额归属问题也尚未完成复核。